

결선 · 8분 발표 + 2분 질의응답

EARLYSIGNAL / FINVIBE

# 신고를 조사 요청서로.

소비자 신고에서 조사해야 할 안전 신호를 더 일찍 찾는 도구

## 조사 요청서

대상 · 기준일

증가와 경보 근거

인용한 신고

미확인 사항

담당자 판단

LLM은 측정하고, 통계는 판단하고, 담당자는 결정합니다.

# 운전자의 신고를, 담당자의 다음 조치로.

설명 상황 예: “주행 중 타는 냄새가 났어요.” → 자동차 회사에서 고객 안전을 살피는 담당자

설명 상황 · 도입 가설

## 운전자의 신고

타는 냄새, 연기, 과열처럼 같은 현상도 서로 다르게 표현됩니다.

설명용 표현 예

## 담당자의 검토

어떤 차종에서 어떤 증상이 평소보다 늘었는지 찾고 실제 원문을 읽습니다.

조사할 후보를 정리

## 조사 요청

“이 차종을 더 살펴봅시다.”

조사할 이유, 근거 신고, 아직 모르는 사항을 문서로 남깁니다.

가치 가설: 고객 안전 담당자가 조사 후보와 근거를 정리하는 시간을 줄인다.

# AI에게 맡기는 일의 경계를 정했습니다.

신고 원문 → 증상 라벨 → 월간 집계 → 경보 → 담당자 결정

역할 분리 설계 · 현재 화면은 LLM 분류

LLM

## 측정

신고 원문을 증상 라벨과  
신고별 요약으로 정리합니다.

원문 · 라벨 · 인용 연결

STATISTICS

## 판단

차종별 증상 건수를  
자신의 과거 수준과 비교합니다.

경보 규칙 · 기준선 공개

HUMAN

## 결정

원문을 인용하거나 제외하고  
조사 착수·보류·기각을 정합니다.

조사 요청서 · 결정 기록

같은 차종의 평소 신고 수준과 비교합니다. 반복되는 증상을 확인하고 사람이 다음 조치를 정합니다.

# LLM은 문장을 정해진 항목으로 바꿉니다.

직접 분류 → 출력 검사 → 캐시 → 월별 집계. 현재 제품은 LLM 분류입니다.

7,502건 LLM 출력 검사 완료 · 분류 정확도 미측정

## 신고 원문

식별정보 정제  
최대 1,500자 입력



## LLM 분류

정해진 증상·위험 요소  
근거 인용·한국어 요약



## 출력 검사

스키마·인용·식별정보 검사  
실패 시 원문 구간 재선택



## 집계에 연결

캐시 완성 후 적용  
같은 범위의 키워드와 비교

## API 출력 검사

7,502건 중 7,502건 통과

분류 정확도를 뜻하지 않음


38개 조사 사례의 통계 백테스트와 별개입니다. 사람 정답 기반 분류 정확도는 미측정입니다.

사람 정답 검수는 전문성·시간 제약으로 당일 미완료입니다. 방법 간 일치율을 정확도로 해석하지 않습니다.

# 이번 달 신고를, 지난 12개월과 비교합니다.

실제 LLM 분류 집계 | HYUNDAI SONATA · 화재·과열 · 2018-08 접수분

실제 신고 건수 · LLM 분류



이번 달

**17건**

고유 신고 번호로 집계  
직전 12개월 기준선

**4.92건**

이번 달은 평균에서 제외  
평소 대비

**3.46배**


2018-09-01부터 확인 가능

접수일로 월을 나눕니다. 0건인 달도 포함하고, 선택한 기준일 뒤의 신고는 보지 않습니다.

# 평소에도 이만큼 나올 수 있는지 묻습니다.

포아송 모형: 평소 평균이 같은 상태에서 이번 달 건수 이상이 나올 확률을 계산합니다.

통계의 역할 · 경보 후보 판단



관측 건수 이상 확률

**0.00161%**

$p = 1.61e-05$

경보 조건

**$p < 0.001$**

그리고 월 3건 이상

이번 사례

**두 조건 충족**

원문을 검토할 후보로 표시

p값은 결함일 확률이 아닙니다. 배수가 커도 확률과 최소 건수 조건을 함께 통과해야 합니다.

# 경보 규칙과, 그 규칙의 검증을 나눕니다.

규칙 선택에 쓴 개발용(dev)과 고정 규칙으로 평가한 검증용(holdout)을 분리했습니다.

등록 사례·대조군 · 키워드 백테스트



정해진 조사 전 기간에 표적 증상 경보가 있었던 사례 수

선정 사례의 경보 발생 비율입니다. 포아송 분포의 적합성이나 일반 정확도를 검증한 값은 아닙니다.

# 접수일 기준으로 과거를 재현합니다.

키워드 기준선: 38회 과거 경보 재계산·64칸 독립 검산. 당시 파일의 공개·수정 이력은 미복원입니다.

미래 접수 차단 확인

탐지에 사용

기준일까지 접수된 신고  
원문 · 증상 라벨 · 과거 건수

평가에서만 확인

이후 실제 신고  
등록 조사 기록의 개시·결과



38개 조사 사례의 기준일에서 키워드 경보를 잘라 재계산해 완료월 결과가 일치했습니다.

# 같은 신고에 적용해도, 더 정확한지는 별도입니다.

동일 데모 모집단의 키워드·LLM 비교입니다. 등록 38사례의 주 검증과 관측 범위가 다릅니다.

같은 모집단 비교 · 일치율은 정확도 아님

## 대표 증상 라벨 일치

# 3,793/7,502

50.56% · 방법 간 일치율

정답을 맞힌 비율은 아닙니다.

## 월별 경보 칸

# 34 → 39

키워드 → LLM · 같은 4,464칸

경보 증가만으로 우위를 말하지 않습니다.

## 지정 예비조사(PE) 대비

# 209일 · 240일

2019.03.29 개시 · 두 방식 동일

볼트: 키워드 놓침 · LLM 23일 늦음

2018년 청원·검토가 이미 있었습니다. 지정 PE 대비 일수이며 기관 최초 인지·조사보다 먼저 찾았다는 뜻은 아닙니다.

# 한 가지 업무를 끝까지 보여줍니다.

공개 배포에서 직접 저장·다운로드한 실제 화면입니다. earlysignal.pages.dev · LLM 분류

실제 브라우저 저장 확인

ES-20180901-HYUNDAI-SONATA-FIRE\_THERMAL

확정됨

조사 요청서 ES-20180901-HYUNDAI-SONATA-FIRE\_THERMAL (확정)

· 조사 대상: SONATA (HYUNDAI) · 화재·과열

· 분석 기준: 2018-08 접수분까지 · 월 집계 확인 가능일 2018-09-01

· 데이터: NHTSA 소비자 신고 · AI 라벨 · 통계 정보

· 실제 저장 시각: 2026-10-09T04:01:49.014Z

· 분석 방식: 현재 공개 파일의 접수일을 기준으로 한 과거 재현

1. 신고 증가와 경보 근거

이번 달 17건, 평소 4.92건, 3.46배 (p=1.613e-5). 연속 경보 1개월.

경보 기준: 이전 12개월 평균 대비 p<0.001, 3건 이상(최소 이력 6개월).

같은 시기 같은 증상 경보 차종: KIA SOUL.

최근 6개월: 2018-03 3건 · 2018-04 5건 · 2018-05 5건 · 2018-06 7건 · 2018-07 7건 · 2018-08 17건

03 · HUMAN DECISION

담당자 판단

근거를 확인한 뒤 다음 조치를 정하세요.

조사 착수

보류

기각

다음 조치 복수 선택

☒ 원문 정밀 검토

☒ 수리·보증 기록 조회

☐ 생산 기록 대조

☐ 부품 공급사 확인

☐ 다음 달 재검토

담당자 메모

대표 신고의 원문을 확인하고 수리·보증 기록과 대조합니다.

## 실제 저장된 요청서

AI 요약 인용·담당자 검토  
판단 입력 → 확정·저장

✓ 저장된 요청서

실제 저장: 2026. 10. 9. 오후 1:01:49

↓ 요청서 Markdown 내려받기

판단 기록 JSON 내려받기 ↓

경보 선택 → 원문 인용·제외 → 담당자 판단 → 요청서 저장. 내려받은 문서까지 확인합니다.

# 실제 업무에서 쓸 만한지 확인하겠습니다.

첫 도입 후보: 자동차 회사의 고객 안전 담당자 | 구매 의사와 실제 사용 가치는 아직 가정

도입 가설

## 누가 쓰나

자동차 회사의 고객 안전 담당자  
원문 검토와 조사 요청서 작성

구매 의사 · 가격은 미확인

## 어떤 가치가 있나

검토 전후에 걸린 시간 비교  
월 경보 수와 제외 이유 기록

감당할 수 있는 업무량 확인

## 어떻게 운영하나

새 신고만 AI가 읽고 결과 저장  
누적 실험 약 \$4.57

반환 사용량 추정 · 실패 포함  
실제 청구액 · 건당 단가와 구분

검토 시간 · 월 경보량 · 요청서 활용률 · 신규 신고 처리 비용을 함께 측정합니다.

# 어떤 판단을 했는지 기록으로 남깁니다.

사용자 선택과 Codex의 구현·독립 검수 결과를 코드·근거·결과로 연결합니다.

이슈·작업트리·PR·독립 검수

## 이슈 · 계획

Step · 완료 기준  
ADR · 데이터 계약



## 분리된 구현

작업트리 · 기능 브랜치  
PR로 변경 제시



## 독립 검수

근거 · 테스트  
실패 · 주장 검토



## 수정 · 통합

검수 지적 반영  
세션 · 커밋 연결

검수 기록에 남길 것

작업 지시 → 실제 결과 → 지적 사항 → 수정 → 재검증 → 통합

8분 발표·데모 종료 → 2분 질의응답. 근거 계산과 미사용 기술의 범위는 부록에서 확인합니다.

# 부록 1. 경보 계산과 모형 가정의 범위.

독립 계산 확인 · 과거 사례 평가 · 확률모형의 적합성은 서로 다른 검사입니다.

규칙은 고정 · 모형 적합성 추가 검증 필요

## 월별 기준선

$n$  = 그달 고유 신고 수  
평균 = 직전 12개월 평균

당월 제외 · 0건 월 포함  
이력 6개월 이상부터 판단  
평균의 하한은 0.5

## 포아송 상위 꼬리

$p = P(X \geq n \mid \text{평균})$   
계산: `poisson.sf(n-1, 평균)`

$p < 0.001$  이고  $n \geq 3$   
두 조건 모두 만족하면 경보  
배수는 설명용 지표

## 검증하지 않은 가정

건수 독립 · 일정한 발생률  
평균과 분산이 같은 모형

과산포 · 계절성 · 보도 영향  
판매 · 운행 노출 미반영  
다중 검정 보정 미적용

작은  $p$ 값만으로 전체 오류율을 보장하지 않습니다. 작은 대조군 · 신고 쏠림 · 노출량 차이도 남아 있습니다.

## 부록 2. 비교 통계와 업무량도 범위를 밝힙니다.

이항 계산은 비교용이며, 포아송이 현재 주 경보 규칙입니다. 업무량은 현업 투입 시간이 아닙니다.

실제 계산 · 주 분석과 보조 분석 분리

### 이항 비교 계산

전체 신고 중 증상 비율 비교  
과거 59/1005 → 이번 달 17/108

$p = 0.0001888$   
코드에서 비교용으로 계산  
주 경보·평가에는 미사용

### 키워드 경보 업무량

차종·월당 경보 수  
사례 0.199 · 대조 0.092

등록 평가창의 관측치  
증상별 경보를 합산한 값  
현업 검토 시간은 미측정

### 키워드 보조 분석

단일 차종으로 좁혀 비교  
사례 8/20 · 대조 1/19

기존 주 분석 결과는 보존  
결과를 보고 규칙 미조정  
차종 중복 등 한계는 유지

서로 다른 지표를 하나의 정확도로 합치지 않습니다. 발생 비율·경보량·모형 적합성·분류 정답은 별개입니다.

## 부록 3. 지정 예비조사 이전에도 검토가 있었습니다.

209일·240일은 지정 PE 개시일 대비입니다. 기관의 최초 인지·최초 조사나 AI의 최초 발견을 뜻하지 않습니다.

공식 사건 이력 · 비교 시점의 한계

더 앞선 2017년에도 현대 RQ17-004 · 기아 RQ17-003 리콜 검토가 있었습니다.

**2018.06.11**

**CAS 청원**

현대·기아 비충돌 화재에  
안전성 조사 요청



**2018.08.21**

**DP18-003 검토**

청원을 받아들일지  
기관이 검토 시작



**2019.03.29**

**PE19-003 · PE19-004**

예비조사 개시  
209일·240일의 비교 지점

**별도 실제 문제** 2018년 12월 연료관 리콜: 엔진 교체 차량 일부의 연료관 문제로 누유·화재 위험.

출처: NHTSA PE19-003·004 개시서, 18V907·934 보고서 · 사후 맥락이며 탐지 입력에는 미사용

리콜 원인을 데모의 모든 신고에 적용하지 않습니다. 날짜 비교는 실제 조사 착수·사고 예방을 앞당긴 효과가 아닙니다.

## 부록 4. 분류와 대표 신고 선택을 구분합니다.

분류는 개별 신고를 읽습니다. 대표 요약 선택은 같은 경보 칸의 기존 요약만 다룹니다.

현재 코드·캐시의 실제 범위

### 신고 분류 출력

주 증상 1개·보조 최대 2개  
위험 요소 6개·심각도 1~3

원문에 있는 인용 200자 이내  
한국어 요약 40자 이내  
모델·프롬프트·원문 해시 저장

### 대표 신고 요약 선택

같은 경보 근거 최대 10건  
AI는 번호 1~3개만 선택

기존 AI 요약을 그대로 복사  
신고 번호로 원문 연결  
수량·시점·인용 검사는 유지

### 사람 정답 검수

독립 30건 검수 자료 준비  
사용자가 직접 검수 시도

전문성·시간 제약으로 미완료  
사람 정답 정확도는 미측정  
전문가 검수는 후속 계획

분류 시험의 인용 실패 14건은 원문 후보 선택으로 개선했습니다. 대표 신고 요약 16개는 별도 출력입니다.

## 부록 5. 형식 통과 뒤에도 의미를 검수했습니다.

신고별 기존 AI 요약을 그대로 인용하도록 사용자가 선택했습니다. 새 종합 문장을 만들지 않습니다.

실패·의미 과장·사용자 선택·수정 기록

### 1. 자유 종합

54회 응답 · 0/18개 통과

인용 검사 실패를 보존  
실패 문장은 공개하지 않음  
재시도 비용도 기록

### 2. 문장별 구조화

첫 1개는 형식 검사 통과

연기·화재·위치를 묶으며  
일부 인용보다 의미가 넓어짐  
제공 요약 대조 후 공개 거부

### 3. 기존 요약 인용

16/18개 공개 출력

AI가 신고 번호만 선택  
기존 신고별 요약 그대로 연결  
2개는 수량 검사에서 거부

기존 AI 요약 자체의 의미 정확도는 미측정입니다. 대표 인용을 전체 신고의 공통 상황이나 원인으로 확대하지 않습니다.

## 부록 6. pgvector·RAG는 확장안으로 구분합니다.

원래 기획의 ‘유사 과거 사례’는 아직 미구현입니다. pgvector/RAG는 이를 보완하기 위한 설계입니다.

사용자 승인 확장 설계 · 현재 미구현

현재 구현

벡터 검색 없음

신고 한 건 → 정제 → 직접 LLM 분류 → 출력 검사 → 집계

자료 정제·임베딩

유사 과거 신고·수리 자료



pgvector 검색

기준일·권한 필터



RAG 근거 요약

출처 ID·인용 연결



담당자 원문 대조

채택·제외·요청서 근거

확장안 · 현재 미구현

검증 계획: 검색 Recall@k · 인용 정확성 · 기준일/권한 누출 · 검토 시간

검색 결과는 담당자의 근거 검토를 돕고, 현재 신고의 자동 라벨에는 다른 신고의 사실을 섞지 않습니다.

분류 검증을 먼저 완료합니다. RAG는 근거 검색 확장으로 설계하며, 효과 지표는 아직 측정하지 않았습니다.

# 부록 7. 제출 기획과 현재 구현의 차이를 남깁니다.

요청서는 원래 기획의 담당자 결정을 구체화했습니다. 사람 정답 검수·유사 사례 검색은 미완료로 남깁니다.

제출 기획 보존 · 미완료·보완 이유 공개

| 제출 기획  | 현재 구현                              | 차이·이유                               | 다음 검증                            |
|--------|------------------------------------|-------------------------------------|----------------------------------|
| 신호 추출  | 고정 16개 증상 코드로 분류<br>위험 요소·인용 출력 검사 | 별도 부품 추출 미구현<br>자유 군집화·벡터 검색 없음     | 같은 표본의 사람 정답 대조<br>검수 예시는 평가와 분리 |
| 변화 탐지  | 월별 집계·포아송 경보<br>현재 제품은 LLM 분류      | 주 38사례 검증은 키워드<br>방법 간 일치율 ≠ 정확도    | 전문가의 원문·정답 검수<br>현업 검토 시간·효용 측정  |
| 신호 브리프 | 대표 신고의 AI 요약 인용<br>담당자 판단을 요청서로 저장 | 새 종합 문장 대신 기존 요약<br>유사 과거 사례 검색 미구현 | 원래 기획의 검색 기능 보완<br>근거·인용·시점 검증   |
| 과거 재현  | 접수일 기준으로 잘라 계산<br>지정 조사일 대비 일수 측정  | 당시 공개 파일 수정 이력은<br>복원하지 못한 한계       | 공개 가능 시점·자료 변경<br>민감도 분석 필요      |

유사 사례는 원래 기획의 미구현 기능입니다. 직접 분류 검증을 먼저 하고, 근거 검색으로 보완합니다.

## 부록 8. 증상 다음에는 조사 질문과 확인 자료가 필요합니다.

현재 제품 완성을 우선합니다. 가설과 확인 절차는 후속 설계이며 실제 원인 추정 기능은 아닙니다.

설계·발표만 · 자료 연결·가설 생성 미구현

### 원문에 명시된 내용

원문에 명시된 증상·상황  
신고 ID와 근거 연결

현재 근거

### 조사 질문·가설

근거와 추론을 구분  
다른 가능한 설명도 기록

후속 설계 · 미구현

### 추가 확인 자료

정비 진단·고장 코드·검사  
작업·부품·생산 이력

후속 설계 · 미구현

### 담당자 확인

지지·반박·보류를 기록  
확인 결과와 출처 보존

후속 설계 · 미구현

### 자료 요구사항

위 정비·검사·생산 자료는 아직 연결하지 않았습니다. 실제 사례의 원인 가설을 생성한 결과도 없습니다.

근거가 부족하면 가설을 보류합니다. 유사한 증상만으로 같은 원인을 부여하거나 확률을 붙이지 않습니다.

현재는 조사 요청서를 완성합니다. 이후의 가설·추가 자료·담당자 확인은 출처와 상태를 나누어 검증합니다.

## 부록 9. 공개 신고를 읽을 때 지켜야 할 기준.

데이터 정의가 바뀌면 경보의 의미도 달라집니다.

실데이터 적재 검산 완료

### 소비자 신고

차량에 대한 소비자 신고만 포함하는 규칙을 적용합니다.

차량 제품으로 한정  
허용 신고 유형을 고정

### 고유 신고

부품별 중복 행을  
신고 건수로 세지 않습니다.

고유 신고 번호로 집계  
브랜드 + 모델, 연식 통합

### 접수 시점

그날 접수된 신고까지만  
탐지 입력으로 사용합니다.

LDATE 기준  
조사 결과 필드는 평가용

원본 1,301,663행 → 소비자 고유 신고 932,821건. 원본 스트리밍 집계와 DB 결과를 독립 대조했습니다.

## 부록 10. 측정과 판단 사이에 재현 가능한 경로.

화면의 숫자가 어느 입력과 규칙에서 나왔는지 추적하는 구조입니다.

채택한 설계



### 입력과 출력의 경계

탐지 코드는 조사 결과를 읽지 않습니다.

웹은 export 값과 사용자의 검토·판단으로 문서를 만듭니다.

파이프라인 출력 → 데이터 계약 → 정적 웹. 화면 수치는 출력 파일에서 가져옵니다.

# 부록 11. 실패와 알려진 약점도 검증의 일부입니다.

볼트 EV 농침을 공개하고, 단일 차종 비교를 주 분석과 분리했습니다.

실패·민감도 분석 확인

## 농침 사례

볼트 EV는 현재 키워드  
기준선에서 농쳤습니다.

사전 시제품의 낮은 경보와  
다른 결과도 그대로 공개.

## 대조군의 품질

신고량이 적은 대조군은  
비교가 쉬워질 수 있습니다.

주 분석을 보존하고  
차종 단위 결과를 별도 확인.

## 평가의 한계

여러 차종을 묶은 사례와  
단일 대조의 단위가 다릅니다.

개발·검증 분할 사이에  
겹치는 차종도 있습니다.

단일 차종 보조 분석: 사례 8/20 · 대조 1/19. 주 분석을 덮어쓰거나 규칙을 다시 맞추지 않았습니다.